RDD en el ciclo ODD: revisión independiente basada en riesgo

Guía para arquitectos empresariales y de soluciones · 26 de octubre de 2026 · Gentle AI 4.x

1. Resumen ejecutivo

Conclusión: RDD (Receipt-Driven Development) es la capa de **revisión independiente** que Gentle AI puede añadir al ciclo ODD. Tras cada commit evalúa el riesgo del cambio y, solo cuando hay riesgo, lanza reviewers con contexto nuevo sobre una versión congelada del cambio, con una bounded correction si hace falta. **No sustituye a la CI ni a la revisión humana, y nunca autoriza una entrega.** Para una organización, RDD es un control intermedio útil, más barato que revisarlo todo y más fiable que la autoverificación del agente que escribió el código. Debe activarse por política según el riesgo del repositorio y complementarse con reglas propias, porque el nivel de riesgo lo decide el clasificador de la herramienta.

- **Dónde actúa en ODD:** en el paso 6, *implementar tarea a tarea*. Tras cada commit de trabajo, y al cerrar cada slice (unas 400 líneas cambiadas).
- **Cómo decide:** por evidencia, no por tamaño. Un cambio grande que solo toca documentación no recibe reviewers; un cambio de dos líneas en autenticación recibe varios.
- **Qué deja:** el nivel de riesgo y el resultado de la revisión, registrados por tarea en el documento de feature.
- **Quién lo controla:** el usuario o la organización. ODD nunca lo activa por su cuenta. Su estado se consulta con `gentle-ai review mode status`.
- **Recomendación:** activarlo en repositorios de riesgo medio y alto, como agentes con herramientas que tienen efectos, seguridad o datos personales. Mantener CI y revisión humana como quality gates de integración en todos los casos.

2. Qué es RDD y qué no es

RDD registra evidencia de revisión independiente y acotada sobre un candidato de cambio congelado, y permite un proceso de corrección también acotado. Sus principios de diseño son:

Principio	Significado
La revisión llega después del candidato	No hay plan previo que aprobar: se revisa lo que realmente se ha escrito
El nivel lo decide la evidencia	El clasificador nombra su propio motivo, así que el coste nunca queda sin explicar
Congelación del candidato	Lo revisado es una versión inmutable del cambio, identificada por su hash; los resultados se ligan a ese hash
Independencia	Los reviewers trabajan con contexto nuevo, separados del agente que implementó

Principio	Significado
Bounded correction	Si hay hallazgos, la corrección tiene un presupuesto de líneas fijado al congelar el candidato
Fallo seguro	Una evaluación fallida nunca equivale a riesgo bajo; un interruptor ilegible no equivale a desactivado
Separado de la entrega	La evidencia de RDD nunca autoriza commits, push, PR ni releases; manda la política del repositorio

RDD es	RDD no es
Una revisión adversarial e independiente, proporcional al riesgo	Una aprobación de entrega
Evidencia registrada por tarea	Un sustituto de la CI, de los tests ni de la revisión humana de la PR
Un control opcional, gestionado por el usuario	Algo que ODD active por su cuenta
Una forma de detectar fallos antes de la PR	Una garantía de ausencia de fallos

Glosario:

Término	Qué es
Candidato	El conjunto de commits que se revisa, congelado e identificado por su hash
Review boundary	El último punto revisado; el primero es el punto de ramificación y cada revisión lo hace avanzar
Nivel de riesgo	Pasivo, bajo, medio o alto, asignado por la evaluación tras cada commit
Lens	Un ángulo de revisión con su propio reviewer; el nivel más alto usa cuatro
Consentimiento	La confirmación que se pide antes de lanzar reviewers en riesgo medio o alto
Bounded correction	El único ciclo de corrección permitido, limitado por un presupuesto de líneas
Slice	Bloque de entrega revisable, de unas 400 líneas cambiadas

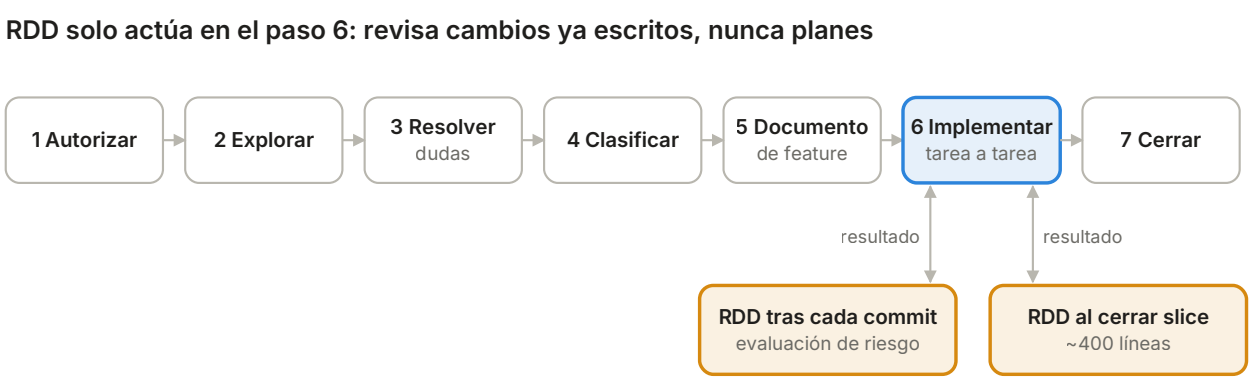
3. Cómo ha evolucionado

Versión	Cambio relevante para RDD
2.3–2.4 (candidatas)	Ciclo completo de revisión con receipts, consentimiento registrado, lenses, refuter y validator; transporte de reviewers común para Claude Code, Codex y OpenCode
2.4.0	**Cambio de valor por defecto:** RDD pasa de activado a desactivado; "una instalación que nadie configuró ya no empieza a revisar sola"; la entrega vuelve a la política del repositorio (hooks, tests, CI)
2.5.0 (candidatas)	Se retiran los receipts compactos y sus delivery gates; "ningún receipt retirado es una aprobación"

Versión	Cambio relevante para RDD
3.0	RDD sale de las fases SDD y queda como interruptor de revisión controlado por el usuario
4.0	La guía de RDD solo se instala para Claude Code, Codex y OpenCode
4.2	El independent verifier solo se ejecuta para un elemento de alto riesgo nombrado

Valor por defecto: compruébalo, no lo supongas. La documentación no es coherente. La guía de uso indica que el instalador propone desactivado, la guía de uso previsto lo describe como activado por defecto, y hay una propuesta abierta para activarlo por defecto. Antes de estandarizar, ejecuta `gentle-ai review mode status` en cada equipo y fija el valor de forma explícita.

4. Dónde encaja en el ciclo ODD



Pasos 1–5: sin revisión RDD. El documento de feature (paso 5) fija la delivery strategy y, con ella, los slices.
Paso 7: el cierre informa de lo fallido o pendiente; los resultados de RDD ya están registrados por tarea.

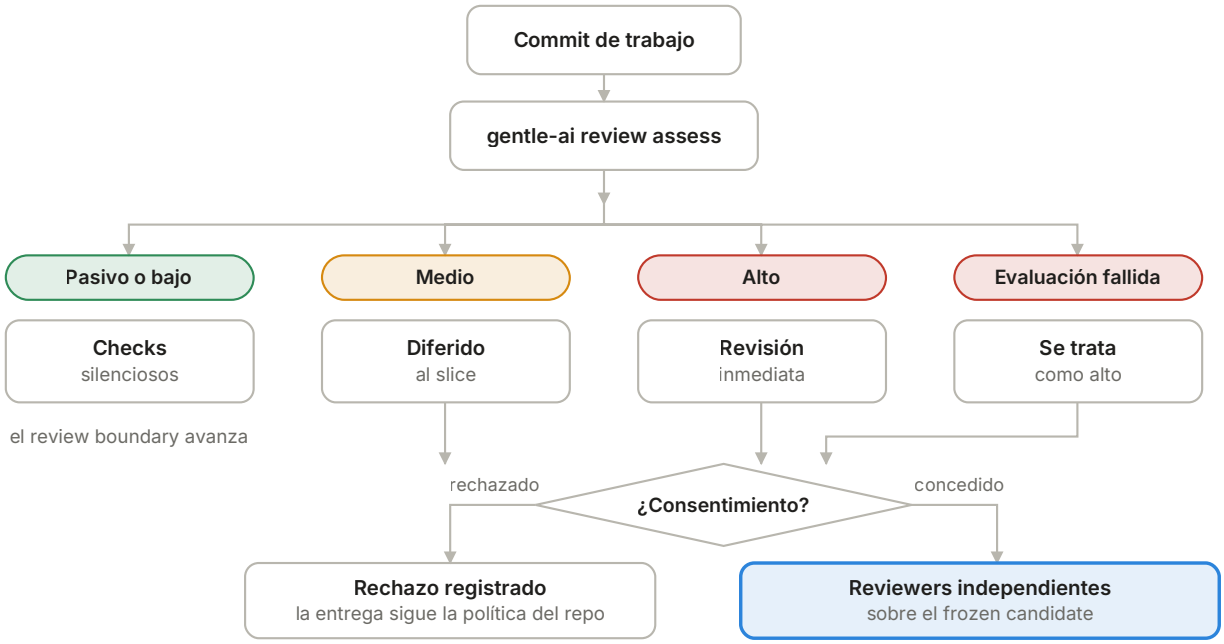
Paso de ODD	Papel de RDD
1–4. Autorizar, explorar, resolver dudas, clasificar	Ninguno: RDD no revisa planes, solo cambios ya escritos
5. Registrar el documento de feature	Se elige la delivery strategy, que define los slices que revisará RDD en riesgo medio
6. Implementar tarea a tarea	**Punto de integración principal:** evaluación tras cada commit y revisión inmediata o diferida según el riesgo
6. Cierre de slice	Revisión de los commits de riesgo medio acumulados desde el último review boundary
7. Cerrar	El informe final incluye los checks fallidos o pendientes; los resultados de RDD ya están en el documento de feature

5. Decisión tras cada commit

Con RDD activado, cada commit de trabajo se evalúa contra el último review boundary:

```
gentle-ai review assess --cwd <repo> --base-ref <último review boundary> --committed-only --json
```

El nivel de riesgo decide si hay revisión y cuándo; un fallo de evaluación cuenta como alto

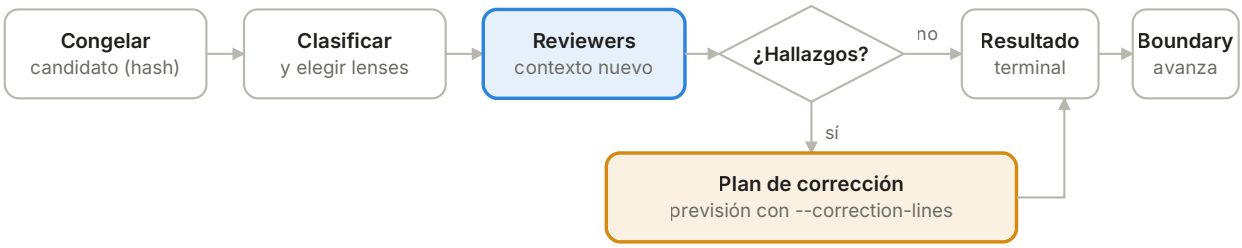


Nivel	Acción	Coste	Resultado registrado
Pasivo o bajo	Checks estructurales sin reviewer ni consentimiento	Mínimo	`passive`
Medio	Consentimiento; revisión al cerrar el slice	Una revisión por slice	`deferred to slice`, después `granted` o `declined`
Alto	Consentimiento; revisión inmediata del commit	Varios reviewers	`granted` o `declined`
Evaluación fallida o no disponible	Se trata como alto	Como alto	`unavailable` y se sigue la continuación nativa

Por qué importa la regla de fallo seguro: si el clasificador falla, el cambio no pasa como inocuo. Es el comportamiento que exigiría cualquier control de seguridad.

6. Ciclo de vida de una revisión

Una revisión: frozen candidate, reviewers en paralelo y como mucho una bounded correction



Una corrección que supera el presupuesto fijado al congelar sale por una vía de abandono auditada.

1. **Congelar:** el candidato queda fijado e identificado por su hash. Nada de lo que cambie después en el working directory altera lo revisado.
2. **Clasificar y elegir lenses:** el nivel determina cuántos reviewers intervienen. El nivel más alto usa cuatro lenses, y en algunas versiones intervienen además roles de refuter y validator.
3. **Revisar:** cada lens produce un resultado ligado al hash congelado. Las citas de los reviewers deben apuntar a ficheros del candidato.
4. **Corregir, una sola vez:** si hay hallazgos, se pide un plan con la previsión de líneas (`--correction-lines`) y se comprueba contra el presupuesto fijado al congelar. Una corrección que se pasa del presupuesto sale por una vía de abandono auditada.
5. **Cerrar:** la revisión termina en un estado final y el review boundary avanza; la siguiente evaluación parte de ahí.

Los detalles internos de este ciclo, como estados, roles y comandos de bajo nivel, proceden de la documentación de arquitectura y de las notas de versión del proyecto, y han cambiado entre versiones. Para gobierno basta con el contrato externo: nivel, consentimiento, revisión independiente, una corrección y resultado registrado.

7. Slices y delivery strategies

ODD prevé las líneas cambiadas a partir de la lista de tareas y lleva la cuenta con cada commit. Al superar unas 400 líneas, aplica la estrategia elegida antes del siguiente commit y registra los límites de slice en el documento de feature. La revisión de riesgo medio cubre los commits acumulados desde el último review boundary, dentro de ese presupuesto.

Estrategia	Comportamiento	Cuándo elegirla
`ask-on-risk` (por defecto)	Pregunta cuando el riesgo lo justifica	Estándar recomendado
`auto-chain`	Encadena slices automáticamente	Cambios largos de bajo riesgo
`single-pr`	Una sola PR para toda la feature	Cambios que deben revisarse juntos

Estrategia	Comportamiento	Cuándo elegirla
`exception-ok`	Acepta superar el presupuesto como excepción	Casos justificados y documentados

Encaje con la política de PR: alinea el tamaño de slice con el tamaño máximo de PR que acepta tu organización. Así cada PR llega con su revisión RDD ya hecha.

8. Qué queda registrado

Cada tarea del documento de feature `odd/tasks/<feature>.md` anota su nivel de riesgo y el resultado de RDD, y el documento incluye los límites de slice. Ejemplo ilustrativo; el formato exacto lo genera la herramienta:

```
## Tareas
- [x] T1 Contrato y tests de fetch_page · riesgo: bajo · RDD: passive · commit a1b2c3d
- [x] T2 Enmascarado de secretos en logs · riesgo: alto · RDD: granted (4 lenses, 1 corrección) · commit d4e5f6a
- [ ] T3 Casos de eval adversariales · riesgo: medio · RDD: deferred to slice

## Slices
- Slice 1: T1–T2 · 312 líneas · cerrada
```

Para auditoría, este registro responde a tres preguntas: qué cambios se consideraron de riesgo, si se revisaron de forma independiente y qué se corrigió. Consérvalo en el repositorio junto con la PR.

9. Lo que RDD nunca hace

- **No autoriza la entrega.** "La evidencia de RDD no autoriza commits, push, pull requests ni releases." La entrega sigue la política del repositorio: hooks, tests, CI y revisión humana.
- **No se salta quality gates existentes.** Los delivery gates que ya tengas se aplican igual, con RDD activado o desactivado.
- **No se activa solo.** ODD nunca lo enciende; la automatización tampoco cambia el interruptor.
- **No inventa aprobaciones.** Desactivarlo no convierte nada en aprobado, y rechazar una revisión queda registrado como rechazo, nunca como aprobación.
- **No revisa planes.** Revisa cambios ya escritos y congelados.

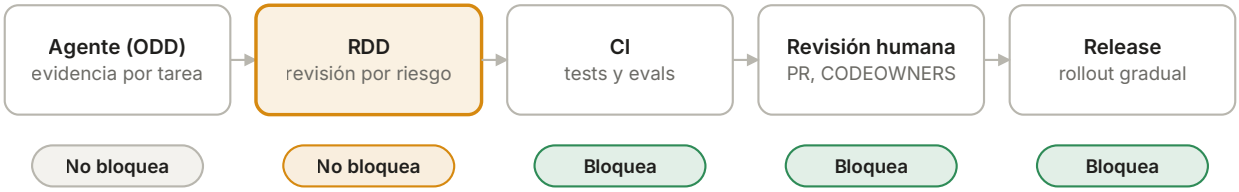
10. Configuración y operación

```
gentle-ai review mode status                  # estado efectivo y su origen (solo lectura)
gentle-ai review mode enable --scope global   # activar para todos los repositorios del equipo
gentle-ai review mode disable                 # desactivar; la entrega sigue la política del repo
```

- **Alcance:** existe un valor global y overrides por clon de repositorio. Una desactivación explícita, global o por clon, siempre se respeta. Usa `gentle-ai review mode --help` para ver las opciones de alcance de tu versión.
- **Instalador:** ofrece RDD activado o desactivado y guarda la elección solo si la instalación termina bien.
- **Tras actualizar Gentle AI:** `gentle-ai sync`, porque los activos gestionados deben coincidir con el binario y las revisiones se niegan a ejecutarse contra activos desalineados.
- **En la app de Claude:** RDD actúa dentro de tus sesiones locales de la pestaña Code. Cuando el riesgo es medio o alto, el agente te pide consentimiento antes de lanzar reviewers.

11. Gobierno: RDD dentro de la defensa en profundidad

RDD aporta evidencia; las capas que bloquean la integración siguen siendo CI, revisión humana y release



Para rutas críticas (seguridad, herramientas con efectos, límites de autonomía), exige además CODEOWNERS y jobs de CI propios: el nivel de riesgo de RDD lo decide el clasificador de la herramienta, no la organización.

Capa	Qué detecta	Quién la controla	¿Bloquea la integración?
Autoverificación ODD	Fallos que el propio agente puede observar	Agente	No
RDD	Fallos que un reviewer independiente detecta en cambios de riesgo	Usuario u organización	No: aporta evidencia
CI	Regresiones, contratos rotos, evals por debajo del umbral	Organización	Sí
Revisión humana	Decisiones de diseño, alcance y riesgo de negocio	Organización	Sí
Release	Impacto en producción	Organización	Sí

Política recomendada según el riesgo del repositorio:

Riesgo del repositorio o agente	RDD	Complemento obligatorio
Bajo (solo lectura, sin datos sensibles)	Opcional, a criterio del equipo	CI y revisión de PR estándar
Medio (herramientas reversibles, fuentes externas)	Activado	Evals de uso de herramientas y robustez en CI
Alto (seguridad, datos personales, acciones con efectos)	Activado y verificado en el arranque de cada sesión	CODEOWNERS de seguridad, evals adversariales, rollout gradual

Límite a tener en cuenta: según la documentación pública, el nivel de riesgo lo asigna el clasificador de Gentle AI y la organización no puede fijarlo. Si una ruta del repositorio siempre debe considerarse de alto riesgo (por ejemplo, `specs/security-control-agent/` o `src/tools/` con efectos), no dependas solo de RDD. Exígelo también con CODEOWNERS y con jobs de CI específicos para esas rutas.

12. Aplicado a la generación de agentes

Con los tres agentes de la guía *ODD aplicado a la generación de agentes*. Los niveles son orientativos: el clasificador decide en cada caso por la evidencia del diff.

Cambio	Agente	Nivel esperable	Comportamiento de RDD	Quality gate que sigue mandando
Corregir una errata en la documentación	Resumen de incidencias	Pasivo	Checks silenciosos	CI estándar
Añadir un caso de eval	Investigación web	Bajo o medio	Silencioso o diferido al slice	CI con la suite de evals
Añadir la herramienta `fetch_page`	Investigación web	Medio	Revisión al cerrar el slice	Evals AC-01 y AC-04 en CI
Cambiar el prompt de citación	Investigación web	Medio	Revisión al cerrar el slice	Evals de regresión
Enmascarado de secretos en logs	Control de seguridad	Alto	Revisión inmediata con varios reviewers	AC-04 en CI y revisión de Seguridad
Ampliar límites de autonomía (§7), por ejemplo permitir `comment_pr` sin confirmación	Control de seguridad	Alto	Revisión inmediata	Aprobación de Seguridad y evals de traza AC-06
Cambiar la lista cerrada de escáneres	Control de seguridad	Alto	Revisión inmediata	Revisión de Seguridad y corpus AC-01 a AC-03

Recomendaciones específicas para agentes:

- **Revisa con RDD el agente que construye agentes.** Lo que más riesgo añade a un agente son sus herramientas con efectos y sus límites de autonomía. Son justo los cambios en los que una revisión independiente aporta más.

- **Las evals no son opcionales aunque RDD apruebe.** RDD revisa código; las evals miden el comportamiento no determinista del agente sobre varias ejecuciones. Son controles complementarios.
- **Pide a los reviewers que lean la spec.** Que el documento de feature cite la spec del agente permite que la revisión compare el cambio con el contrato, no solo con el código.

13. Coste y rendimiento

- **El nivel es la palanca de coste.** El nivel más bajo no usa reviewers y el más alto usa cuatro, así que el coste sigue al riesgo y no al tamaño del cambio.
- **Añade tiempo de revisión y coste de modelo.** Con una suscripción de Claude, las revisiones consumen del mismo cupo que tus sesiones. En repositorios de bajo riesgo puede no compensar.
- **Rechazar una revisión es legítimo.** Rechazar el consentimiento en un candidato concreto no apaga RDD: el siguiente candidato vuelve a preguntar. Úsalo con criterio y no como costumbre, porque el rechazo queda registrado.
- **Mide antes de generalizar:** revisiones por semana, proporción por nivel y hallazgos por revisión. Si casi todo sale pasivo, el coste es bajo. Si casi todo sale alto, revisa la granularidad de los commits.

14. Riesgos y mitigaciones

Riesgo	Señal	Mitigación
Confundir evidencia con aprobación	PR integradas "porque RDD las revisó"	Política explícita: CI y revisión humana siguen siendo obligatorias
Valor por defecto distinto al esperado	Equipos sin revisiones creyendo que están activas	`gentle-ai review mode status` en la incorporación y en auditorías periódicas
Clasificación de riesgo insuficiente para tu contexto	Cambios críticos clasificados como bajos	CODEOWNERS y CI por rutas críticas, independientes de RDD
Rechazos sistemáticos	Muchos `declined` en los documentos de feature	Revisar los motivos; endurecer la política en repos de riesgo alto
Coste en cupo de la suscripción	Límites de uso alcanzados antes de lo previsto	Activarlo solo donde el riesgo lo justifique; vigilar `/status`
Deriva entre versiones	Comportamiento distinto tras actualizar	Leer notas de versión, `gentle-ai sync` y prueba piloto antes de generalizar

15. Métricas

Métrica	Qué indica
Distribución por nivel (pasivo, bajo, medio, alto)	Perfil de riesgo real del trabajo de los agentes
Hallazgos por revisión y proporción corregida	Valor que aporta RDD

Métrica	Qué indica
Proporción de `declined` frente a `granted`	Disciplina de uso
Defectos detectados en CI o en producción tras una revisión RDD	Lo que RDD no está detectando
Coste o tiempo añadido por revisión	Si compensa en cada tipo de repositorio

16. Checklist para arquitectos

☐ Estado de RDD verificado con `gentle-ai review mode status` y fijado de forma explícita por tipo de repositorio

☐ Política escrita: RDD aporta evidencia y nunca sustituye a CI ni a la revisión humana

☐ RDD activado en repositorios de riesgo medio y alto, incluidos todos los agentes con herramientas que tienen efectos

☐ CODEOWNERS y jobs de CI específicos para rutas críticas, independientes del clasificador

☐ Tamaño de slice alineado con el tamaño máximo de PR de la organización

☐ Documentos de feature conservados en el repositorio como evidencia de revisión

☐ Métricas de nivel, hallazgos y rechazos revisadas trimestralmente

☐ Notas de versión de Gentle AI revisadas antes de cada actualización mayor

Fuentes

- Gentle AI: uso, ODD y RDD
- Gentle AI: uso previsto
- Gentle AI: arquitectura de RDD orgánico
- Notas de versión de Gentle AI (2.3–2.5)
- Bounded correction y frozen candidate (PR #3483)
- Propuesta de RDD activado por defecto (issue #4801) · PR #4803
- Gentle AI v4.0.0 · v4.2.0